

1.1)

η	a=0.5	a=1	a=2	a=5
.001	>1000	>1000	>1000	990
.01	760	414	223	97
.03	252	137	73	31
.1	65	40	21	8
.3	24	12	5	8
1	6	1	DT	Div
3	6	div	Div	div
Fastest	2	1	0.5	0.25
Divergence threshold	4	2	1	0.5

1.2)

Como se pode observar, quanto mais pequeno for o η , mais interações o algoritmo fará, sendo que é preciso ter cuidado para não ter um η pequeno demais. Por outro lado, um η demasiado grande leva a que o algoritmo não converja. Além disso é importante referir, que o η deve ser escolhido de acordo com o parâmetro a . É também importante que o valor de η seja inferior a $\frac{2}{a}$ que corresponde ao divergence threshold (neste caso $-x^{(t)} = x^{(t+1)}$):

$$\begin{aligned}
 -x^0 &= x^0 - \eta x^0 a \\
 0 &= 2x^0 - \eta x^0 a \\
 0 &= x^0 (2 - \eta a) \\
 \eta_d &= \frac{2}{a} \\
 \downarrow \\
 \text{divergence}
 \end{aligned}$$

1.3)

Tal como foi visto na aula de problemas, o valor de η que faz o algoritmo convergir mais rapidamente é $\eta = \frac{1}{a}$, pois:

Handwritten notes on grid paper showing the derivation of the optimal step size η for a linear function $f(x) = ax$.

$$\begin{aligned} \left\{ \begin{aligned} x^{(j+1)} &= x^{(j)} + \Delta x^{(j+1)} \\ \Delta x^{(j+1)} &= -\eta \nabla f(x^{(j)}) \end{aligned} \right. \quad \nabla f(x) = ax \end{aligned}$$

$$f(x^*) = 0 \Rightarrow x^* = 0$$

$$\left\{ \begin{aligned} 0 &= x^{(0)} + \Delta x^1 \\ \Delta x^1 &= -\eta a x^{(0)} \end{aligned} \right. \quad \left\{ \begin{aligned} x^{(1)} &= \eta a x^{(0)} \\ - & \end{aligned} \right. \quad \left\{ \begin{aligned} \eta &= \frac{1}{a} \\ - & \end{aligned} \right.$$

Não. Basta o $x^{(0)}$ corresponder a um ponto estacionário (máximo, mínimo ou ponto de sela) e o algoritmo não vai ficar preso (não irá avançar). Isto deve-se a que nestes pontos, o declive (gradiente em \mathbb{R}^1) corresponde a 0 e por isso:

Handwritten notes on grid paper showing the update rule for $x^{(t+1)}$ and the result when the gradient is zero.

$$x^{(t+1)} = x^{(t)} - \eta \underbrace{\nabla f(x^{(t)})}_0$$

$$x^{(t+1)} = x^{(t)}$$

2.1)

η	a=2	a=20
.01	448	563
.03	143	186
.1	43	DT
.3	13	Div
1	DT	Div
3	Div	Div
Fastest	0.6	0.095
Divergence threshold	1	0.1

2.2)

Tal como acontece em \mathbb{R}^1 com a parábola algo semelhante ocorre em \mathbb{R}^2 para o paraboloíde.

Como se pode observar, com η que não seja exagerado pequeno que hajam muitas iterações, ou grande demais que o algoritmo divirja, consegue-se chegar ao mínimo da função dada, sendo que este η deverá ser maior para α maior. Outra coisa importante frisar, é que devido a no algoritmo de *gradient descent*, a cada iteração, o próximo x será sempre um ponto localizado num plano que tem a mesma direção que o gradiente, para o $\alpha=20$, demorará mais iterações a convergir pois o gradiente não está tão direcionado, para o mínimo da função.

2.3)

Não, porque ao aumentar α em \mathbb{R}^1 não se está a dificultar a tarefa de convergir (tendo em conta que se escolheu um bom valor de η) enquanto que neste caso, ao aumentar a largura do vale (α) tal tarefa é dificultada pois o algoritmo aproxima-se cada vez mais lentamente do centro devido à direção do gradiente. Assim quanto maior for α maior será o número mínimo de iterações para funções \mathbb{R}^2 . Apenas é possível chegar ao mínimo da função numa iteração, quando $\alpha = 1$ pois o gradiente irá apontar para o ponto mínimo da função.

3.1)

η	$\alpha = 0$	$\alpha = .5$	$\alpha = .7$	$\alpha = .9$	$\alpha = .95$
.003	>1000	>1000	>1000	>1000	>1000
.01	563	558	552	516	448
.03	186	181	178	115	172
.1	DT	48	35	91	122
.3	Div	DT	29	83	92
1	Div	Div	div	92	146
3	Div	div	Div	div	147
10	div	div	div	div	Div
Divergence threshold	.1	.3	.567	1.9	3.9

3.2)

Como podemos observar quanto maior o α menor será a influência do η , isto é claramente observado para $\alpha = 0.95$. Além disso, podemos observar que ao aumentar o α para η suficientemente pequeno, permite o algoritmo convergir mais facilmente. Também se nota que α tem relativamente pouca influência no número de iterações.

4.1)

N. of tests	α	$\eta \rightarrow$	-20%	-10%	Best ($\eta = 0.015$)	+10%	+20%
≈ 12	0.23	N. of iterations \rightarrow	667	499	25	Div	Div

4.2)

É difícil de encontrar valores que resultem em poucas iterações porque os parâmetros são bastante sensíveis, como se pôde observar para uma variação de 10% causa que o algoritmo divirja ou que o número de iterações aumente substancialmente. Em relação ao α este não deve ser muito grande, para que o algoritmo não tenha muita inércia.

4.3)

η	$\alpha = 0$	$\alpha = .5$	$\alpha = .7$	$\alpha = .9$	$\alpha = .95$	$\alpha = .99$
.001	596	298	236	140	198	167
.01	565	287	221	190	200	165
.1	769	389	214	183	172	152
1	729	396	233	160	137	173
10	672	383	239	173	124	133

4.4)

	N. of tests	η	α	N. of iterations
Without adaptative steps	20	-10%	0.3	>1000
		Best ($\eta = 0.0034$)		127
		+10%		Div
With adaptive step sizes	9	-10%	0.99	262
		Best ($\eta = .001$)		209
		+10%		363

4.5)

Podemos ver que o valor do η não tem grande influência no caso do passo adaptativo pois neste caso as variações de $\pm 10\%$ não irão afetar o resultado de forma drástica apenas um ligeiro aumento no número de iterações. Neste caso o valor inicial do step não terá grande influencia pois este vai sofrer alterações ao longo do correr do algoritmo. Com passo fixo podemos ver que uma pequena variação de η vai gerar resultados não satisfatórios.

Em relação à convergência com e sem o *momentum term* pode-se compreender que a existência deste termo inercial facilita a convergência do método, sendo que quando se inclui

este termo alguns dos ϵ faz com que o algoritmo passe a convergir ao invés de divergirem.